



Prof. MSc. Hugo Menezes Barra

Atividade Prática: Introdução à MLOps e Engenharia de Dados

Contexto do Cenário

A fintech **CredTech** utiliza um pipeline automatizado de inteligência artificial para análise de crédito. A API de captação de clientes passou por uma atualização não homologada e começou a enviar cadastros com inconsistências estruturais e de dados no seguinte formato:

```
dados_brutos = [  
    {"id": 101, "idade": 30, "renda": 4500},  
    {"id": 102, "idade": "desconhecido", "renda": 3200},  
    {"id": 103, "idade": 0, "renda": -1000},  
    {"id": 104, "idade": 42, "renda": None},  
]
```

Atualmente, o filtro de Engenharia de Dados utilizado pelo sistema para tratar a base antes do treinamento é o seguinte:

```
dados_limpos = [  
    d for d in dados_brutos  
    if d["idade"] is not None and d["renda"] is not None  
]
```

Problema detectado: Na segunda-feira de manhã, a pipeline quebrou durante a execução automática e interrompeu a esteira de concessão de crédito em produção.

Questões

1. [Engenharia de Dados — Diagnóstico]: Explique detalhadamente por que a validação atual baseada em 'is not None' falhou em impedir a quebra do código ao processar o registro id: 102. Qual erro específico esse tipo de dado ocasionaria na fase de treinamento do modelo ?

2. [Engenharia de Dados — Implementação]: Reescreva e teste o trecho de código em Python referente à etapa de sanitização/ETL (dados_limpos = ...) de forma a garantir que apenas registros com 'idade' e 'renda' válidos (numéricos e estritamente maiores que zero) sejam mantidos na base.

3. [MLOps — Governança e Qualidade]: Suponha que, após aplicar o seu novo filtro em um lote de 1.000 clientes, 950 registros fossem descartados por corrupção de dados. Se os 50 registros restantes resultassem em uma acurácia simulada de 98%, o sistema de MLOps deveria aprovar esse modelo automaticamente para produção? Justifique sua resposta considerando boas práticas de governança, 'Data Drift' e monitoramento.