

Atividade Prática de Engenharia de Dados MLOPS - Aula 1

Aluna: Nyrx Oliveira de Aquino Farias.

Github Aula 1: [GitHub](#).

Questões 1. [Engenharia de Dados — Diagnóstico]: Explique detalhadamente por que a validação atual baseada em 'is not None' falhou em impedir a quebra do código ao processar o registro id: 102. Qual erro específico esse tipo de dado ocasionaria na fase de treinamento do modelo ?

O filtro 'is not None' falhou porque ele verifica apenas se o valor é diferente de 'None', mas não valida o tipo do dado, sua consistência ou se ele atende às regras de negócio esperadas. No registro 'id: 102', o campo 'idade' possui o valor 'desconhecido'. Como uma string preenchida não é considerada 'None' em Python, a expressão '"desconhecido" is not None' retorna 'True', fazendo com que o registro inválido passe pelo filtro. Além disso, o registro 'id: 103' também passa pela validação, pois 'idade = 0' e 'renda = -1000' não são nulos, porém representam valores inválidos para o contexto de análise de crédito.

O problema é identificado na etapa de treinamento do modelo, quando bibliotecas como o 'scikit-learn' tentam converter os dados para um formato numérico. Nesse momento, o valor '"desconhecido"' causa um erro semelhante a:

ValueError: could not convert string to float: 'desconhecido'

Isso ocorre porque algoritmos tradicionais de Machine Learning não conseguem processar textos em campos numéricos sem um tratamento prévio. A causa raiz foi uma validação de dados insuficiente, que verificava apenas valores nulos e não considerava tipos, formatos e regras de negócio. A solução seria implementar uma etapa de validação de qualidade dos dados, garantindo que os campos possuam tipos corretos, valores aceitáveis e tratamento adequado antes do treinamento do modelo.

2. [Engenharia de Dados — Implementação]: Reescreva e teste o trecho de código em Python referente à etapa de sanitização/ETL (dados_limpos = ...) de forma a garantir que apenas registros com 'idade' e 'renda' válidos (numéricos e estritamente maiores que zero) sejam mantidos na base.

```
dados_brutos = [
    {"id": 101, "idade": 30, "renda": 4500},
    {"id": 102, "idade": "desconhecido", "renda": 3200},
    {"id": 103, "idade": 0, "renda": -1000},
    {"id": 104, "idade": 42, "renda": None},
]

def is_valido(valor):
    # Retorna True se:
    # - o valor for numérico (int ou float), OU convertível para float
    # - E for estritamente maior que zero
    # Retorna False para None, strings não numéricas, zero ou negativos.

    try:
        num = float(valor)
        return num > 0
    except (TypeError, ValueError):
        return False
```

```

# ETL / Sanitização corrigida
dados_limpos = [
    d for d in dados_brutos
    if is_valido(d["idade"]) and is_valido(d["renda"])
]

# informe
print("=" * 45)
print(f" Registros originais : {len(dados_brutos)}")
print(f" Registros válidos   : {len(dados_limpos)}")
print(f" Registros descartados: {len(dados_brutos) - len(dados_limpos)}")
print("=" * 45)
print("\nDados aprovados no ETL:")
for d in dados_limpos:
    print(f" {d}")

print("\nDados rejeitados:")
rejeitados = [d for d in dados_brutos if d not in dados_limpos]
for d in rejeitados:
    motivo = []
    if not is_valido(d["idade"]):
        motivo.append(f"idade inválida ({d['idade']!r})")
    if not is_valido(d["renda"]):
        motivo.append(f"renda inválida ({d['renda']!r})")
    print(f" id={d['id']} → {' , '.join(motivo)}")

```

Saída:

```

=====
Registros originais : 4
Registros válidos   : 1
Registros descartados: 3
=====

Dados aprovados no ETL:
{'id': 101, 'idade': 30, 'renda': 4500}

Dados rejeitados:
id=102 → idade inválida ('desconhecido')
id=103 → idade inválida (0), renda inválida (-1000)
id=104 → renda inválida (None)

```

3. [MLOps — Governança e Qualidade]: Suponha que, após aplicar o seu novo filtro em um lote de 1.000 clientes, 950 registros fossem descartados por corrupção de dados. Se os 50 registros restantes resultassem em uma acurácia simulada de 98%, o sistema de MLOps deveria aprovar esse modelo automaticamente para produção? Justifique sua resposta considerando boas práticas de governança, 'Data Drift' e monitoramento.

Não. Pois, apesar da acurácia simulada de 98%, essa métrica foi obtida utilizando apenas 50 registros válidos de um lote inicial de 1.000 clientes, ou seja, apenas 5% dos dados originais. Esse volume reduzido não garante que a avaliação seja estatisticamente confiável ou que represente corretamente o comportamento dos clientes. Além disso, o descarte de 95% dos registros indica um grave problema de qualidade de dados. Esse comportamento pode ser um sinal de falha na ingestão, alteração indevida na fonte dos dados ou possível Data Drift, onde a distribuição dos dados recebidos pela aplicação muda em relação aos dados utilizados anteriormente pelo modelo.

A aprovação automática nesse cenário poderia gerar um modelo com desempenho aparentemente alto, mas incapaz de generalizar corretamente para dados reais. Também existe o risco de viés, pois os registros restantes podem não representar a população completa de clientes. Segundo boas práticas de MLOps, antes da implantação seria necessário bloquear a promoção do modelo, investigar a causa da corrupção dos dados, validar a qualidade da base, analisar possíveis alterações na distribuição dos dados e realizar testes adicionais em conjuntos independentes.

Portanto, a acurácia de 98% isoladamente não é suficiente para aprovar o modelo. A decisão deve considerar qualidade dos dados, representatividade da amostra, monitoramento de Data Drift e processos de governança antes da entrada em produção.